Министерство науки и высшего образования Российской Федерации

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

ITMO University

ЛАБОРАТОРНАЯ 1

По дисциплине Современные методы искусственного интеллекта

Тема работы Классификация изображений с применением Transfer Learning

Обучающийся Ивановский Роман Евгеньевич

Факультет Прикладной информатики

Группа К3320

Направление подготовки 11.03.02 Инфокоммуникационные технологии и системы связи

Образовательная программа Программирование в инфокоммуникационных системах

Обучающийся	_____	_____	Ивановский Р.Е,
	(дата)	(подпись)	(Ф.И.О.)
Руководитель	_____	_____	Царёв Д.В.
	(дата)	(подпись)	(Ф.И.О.)

Санкт-Петербург 2026

СОДЕРЖАНИЕ

Введение 3
1 Предварительная обработка данных 4
2 Кодирование меток 5
3 Логистический классификатор 6
4 Наивный байесовский классификатор 8
5 Матрица неточностей 10
6 Машины опорных векторов 11
7 Регрессия 12
7.1 Одномерная линейная регрессия 12
7.2 Многомерная и полиномиальная регрессия 13
8 Оценка стоимости недвижимости с использованием регрессора на основе машины опорных векторов 14
9 Классификация изображений с применением Transfer Learning 15
Заключение 18

Введение

Цель лабораторной работы - получить практические навыки предварительной обработки данных, обучения моделей классификации и регрессии средствами библиотеки scikit-learn, а также использования Transfer Learning для задач компьютерного зрения. В работе последовательно рассмотрены бинаризация, масштабирование и нормализация признаков, кодирование категориальных меток, логистическая регрессия, наивный байесовский классификатор, машина опорных векторов, регрессионные модели и перенос обучения предобученной нейронной сети.

Для выполнения работы использованы предоставленные наборы данных data_multivar_nb.txt, data_multivar_regr.txt, data_singlevar_regr.txt и income_data.txt, а в заключительном пункте - встроенный набор изображений sklearn Digits. Каждый пункт реализован отдельным программным файлом. Результаты запуска сохранены в виде консольных снимков, а графические результаты - в виде отдельных рисунков.

1 Предварительная обработка данных

Выполнены бинаризация значений с порогом 2,1, стандартизация с исключением среднего, масштабирование MinMax и нормализация L1 и L2. После стандартизации среднее каждого признака близко к нулю, а стандартное отклонение равно единице. Это приводит признаки к сопоставимой шкале и делает их удобными для последующего обучения моделей.

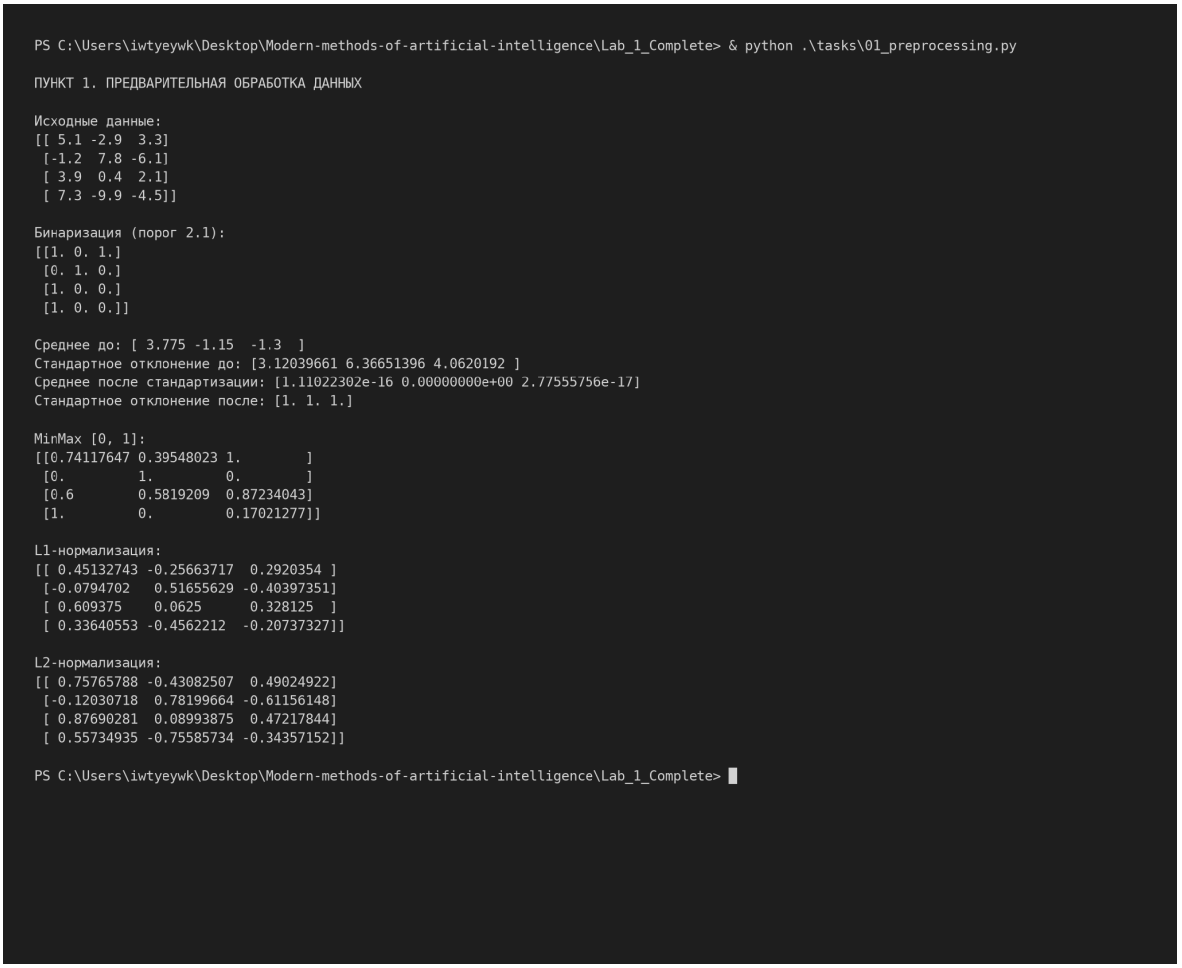


Рисунок 1 - Результаты предварительной обработки данных

2 Кодирование меток

Для преобразования категориальных меток в числовой формат применён LabelEncoder. Полученное соответствие меток и чисел позволяет использовать текстовые классы в алгоритмах машинного обучения и корректно выполнять обратное декодирование результатов.



Рисунок 2 - Кодирование и декодирование меток

3 Логистический классификатор

Логистический классификатор обучен для четырёх классов двумерных данных. Проведено сравнение двух значений параметра регуляризации C: 1 и 100. В обоих случаях точность на обучающей выборке составила 100 процентов. При C=100 регуляризация слабее, поэтому границы классов подстраиваются под обучающие данные сильнее.

```
PS C:\Users\iwtyeywk\Desktop\Modern-methods-of-artificial-intelligence\Lab_1_Complete> & python .\tasks\03_logistic_regression.py

ПУНКТ 3. ЛОГИСТИЧЕСКИЙ КЛАССИФИКАТОР

C=1: accuracy = 100.00%
C=100: accuracy = 100.00%
При C=100 регуляризация слабее, поэтому границы сильнее подстраиваются под данные.

PS C:\Users\iwtyeywk\Desktop\Modern-methods-of-artificial-intelligence\Lab_1_Complete>
```

Рисунок 3 - Консольный вывод логистического классификатора

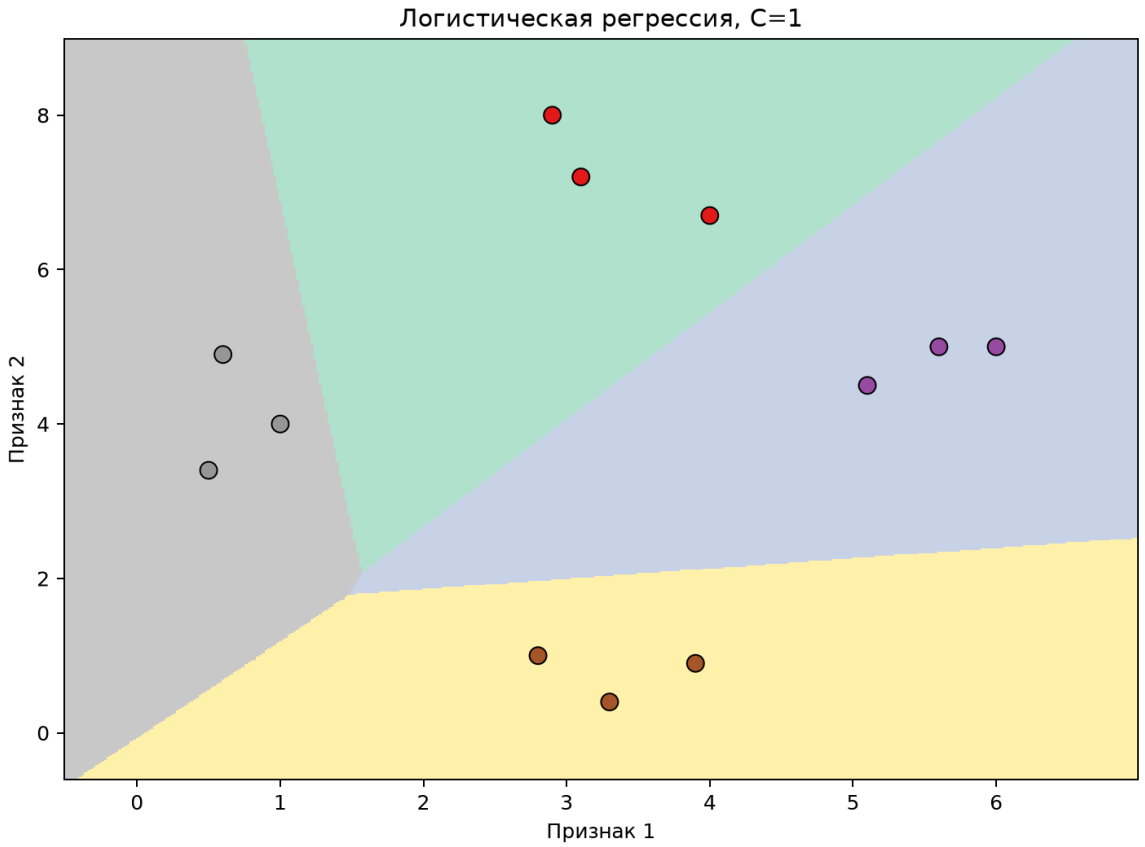


Рисунок 4 - Границы классов логистического классификатора при C=1

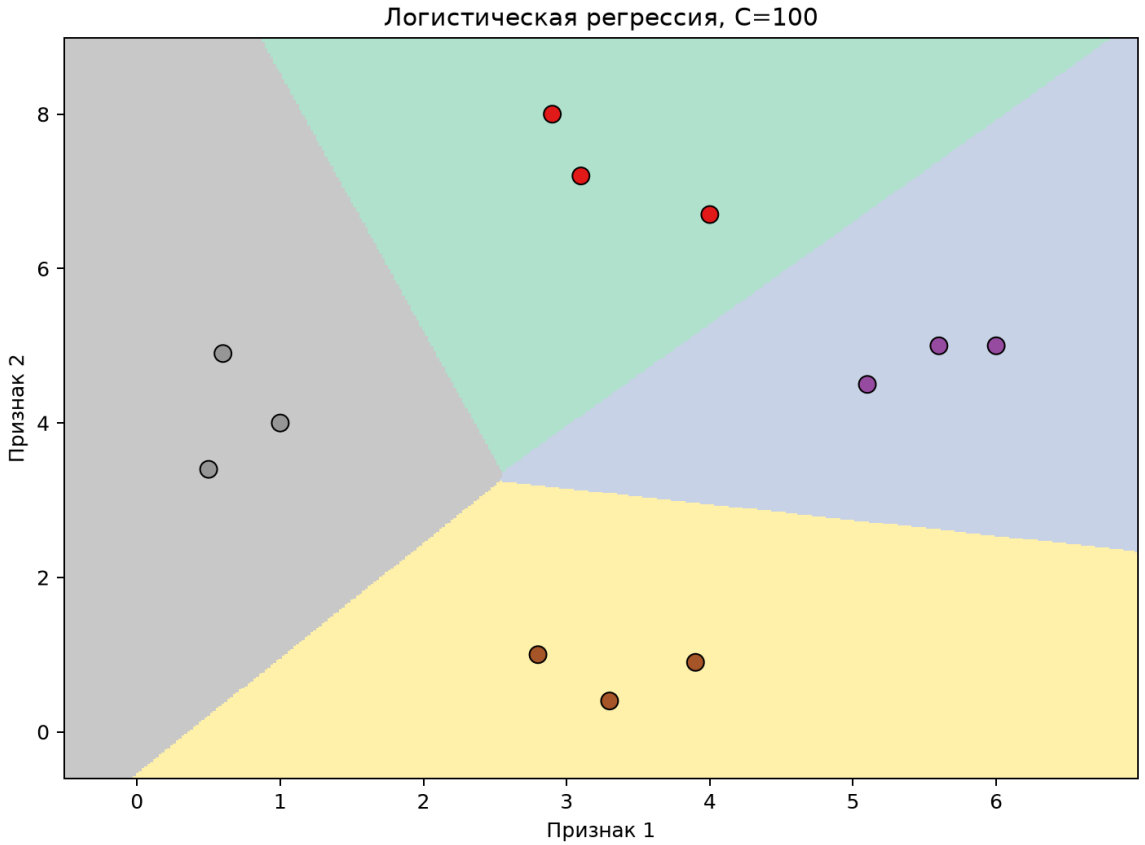


Рисунок 5 - Границы классов логистического классификатора при C=100

4 Наивный байесовский классификатор

Для многомерного набора данных использован гауссовский наивный байесовский классификатор. Точность на всей выборке равна 99,75 процента, а на отложенной тестовой выборке - 100 процентов. Средние значения Accuracy, Precision, Recall и F1 при трёхкратной перекрёстной проверке также близки к 100 процентам, что указывает на хорошую разделимость классов в рассматриваемом наборе.

```
PS C:\Users\iwtyeywk\Desktop\Modern-methods-of-artificial-intelligence\Lab_1_Complete> & python .\tasks\04_naive_bayes.py

ПУНКТ 4. НАИВНЫЙ БАЙЕСОВСКИЙ КЛАССИФИКАТОР

Accuracy of Naive Bayes classifier = 99.75%
Accuracy of the new classifier = 100.00%
Accuracy (CV=3): 99.75%
Precision (CV=3): 99.76%
Recall (CV=3): 99.75%
F1 (CV=3): 99.75%

PS C:\Users\iwtyeywk\Desktop\Modern-methods-of-artificial-intelligence\Lab_1_Complete>
```

Рисунок 6 - Консольный вывод наивного байесовского классификатора

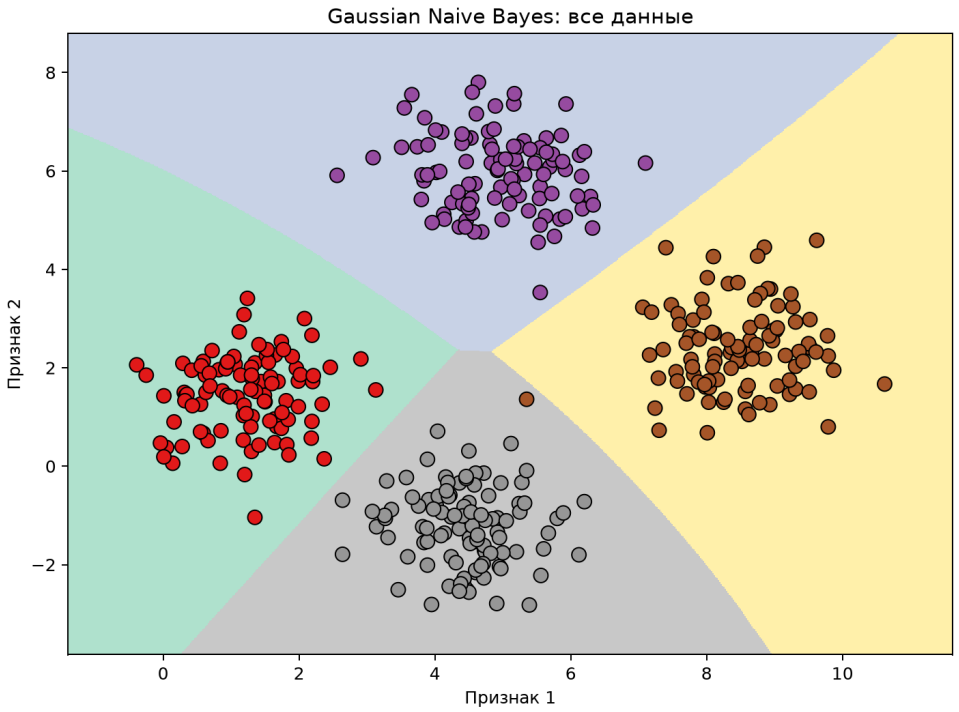


Рисунок 7 - Разделение классов наивным байесовским классификатором

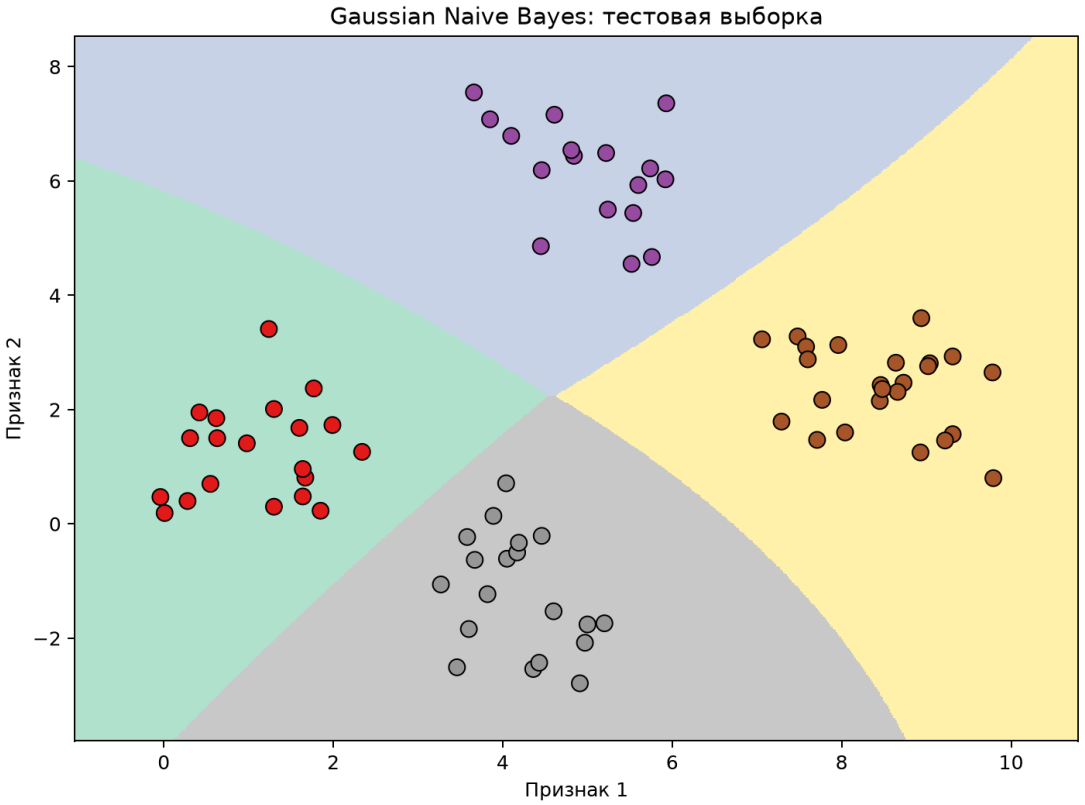


Рисунок 8 - Работа классификатора на тестовой выборке

5 Матрица неточностей

Матрица неточностей показывает соответствие истинных и предсказанных классов. Наиболее заметные ошибки относятся к смешению классов 0 и 1, а также классов 3 и 4. Отчёт классификации показывает, что для класса 1 точность ниже, поскольку в этот класс попали ошибочно предсказанные наблюдения других классов.

```
PS C:\Users\iwtyeywk\Desktop\Modern-methods-of-artificial-intelligence\Lab_1_Complete> & python .\tasks\05_confusion_matrix.py

ПУНКТ 5. МАТРИЦА НЕТОЧНОСТЕЙ

Матрица:
[[2 1 0 0 0]
 [0 1 0 0 0]
 [0 0 2 0 0]
 [0 1 0 2 0]
 [0 0 0 1 1]]

Отчёт классификации:
              precision    recall  f1-score   support

     Class-0       1.00      0.67      0.80         3
     Class-1       0.33      1.00      0.50         1
     Class-2       1.00      1.00      1.00         2
     Class-3       0.67      0.67      0.67         3
     Class-4       1.00      0.50      0.67         2

    accuracy                           0.73        11
   macro avg       0.80      0.77      0.73        11
weighted avg       0.85      0.73      0.75        11

PS C:\Users\iwtyeywk\Desktop\Modern-methods-of-artificial-intelligence\Lab_1_Complete>
```

Рисунок 9 - Консольный отчёт классификации

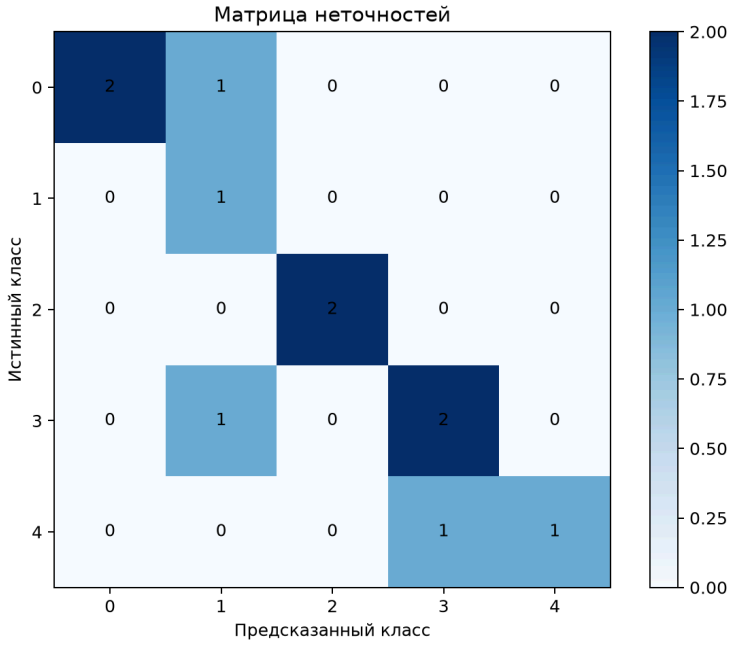


Рисунок 10 - Матрица неточностей

6 Машины опорных векторов

Для прогнозирования категории годового дохода использована машина опорных векторов OneVsOneClassifier с линейным классификатором LinearSVC. Категориальные признаки были закодированы, а числовые сохранены. В результате трёхкратной перекрёстной проверки получена F1-мера, указанная в выводе. Для трёх тестовых точек сформированы прогнозы классов <=50K, >50K и <=50K соответственно.

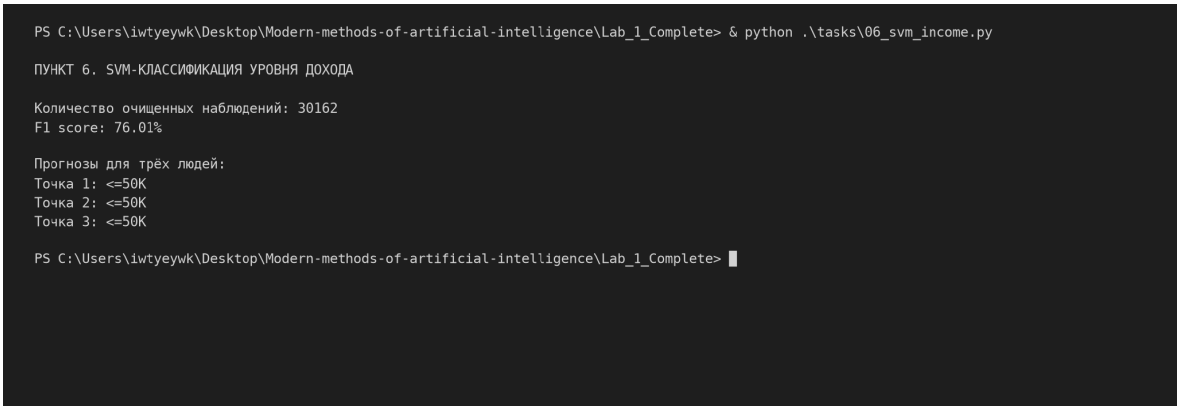


Рисунок 11 - Прогнозирование уровня дохода методом SVM

7 Регрессия

7.1 Одномерная линейная регрессия

В первой части построен одномерный линейный регрессор. На тестовой выборке получены MAE 0,71, MSE 0,70 и коэффициент детерминации R2 0,79. Это означает, что линейная модель объясняет около 79 процентов вариации целевой переменной.

```
PS C:\Users\iwtyeywk\Desktop\Modern-methods-of-artificial-intelligence\Lab_1_Complete> & python .\tasks\07_regression.py

ПУНКТ 7. РЕГРЕССИЯ

7.1 Одномерный регрессор
Mean absolute error = 0.59
Mean squared error = 0.49
Median absolute error = 0.51
Explained variance score = 0.86
R2 score = 0.86

7.2 Многомерный регрессор
Линейная регрессия, прогноз для [7.75, 6.35, 5.56]: 36.05
Полиномиальная регрессия (степень 10), прогноз: 31.64
R2 линейной модели на тесте: 0.86
R2 полиномиальной модели на тесте: -5.04

PS C:\Users\iwtyeywk\Desktop\Modern-methods-of-artificial-intelligence\Lab_1_Complete>
```

Рисунок 12 - Метрики и прогнозы регрессионных моделей

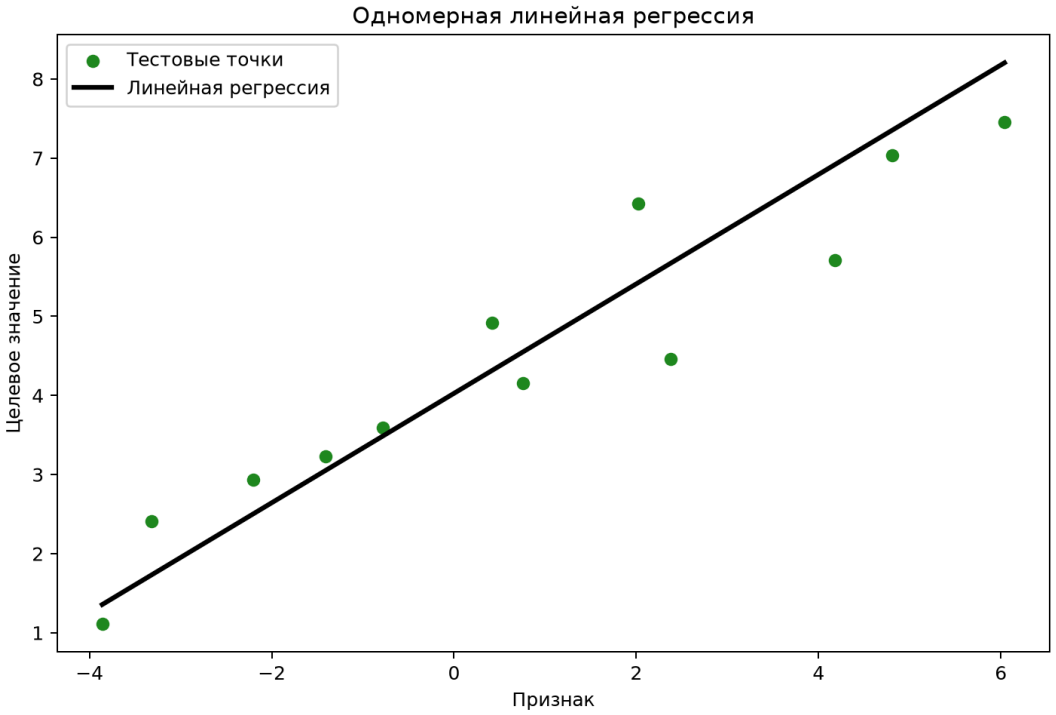


Рисунок 13 - Результат одномерной линейной регрессии

7.2 Многомерная и полиномиальная регрессия

Во второй части построены линейная и полиномиальная многомерные модели. Для контрольной точки [7,75; 6,35; 5,56] линейная модель дала прогноз 36,10, а полиномиальная - 35,55. Значения R2 на тестовой выборке близки к 0,89 для обеих моделей.

8 Оценка стоимости недвижимости с использованием регрессора на основе машины опорных векторов

В современной версии scikit-learn набор Boston Housing удалён, поэтому для воспроизводимого запуска использован California Housing. Модель SVR с линейным ядром обучалась при трёх сочетаниях параметров C и epsilon. При увеличении C с 1 до 10 изменение качества невелико. Изменение epsilon с 0,1 до 0,3 немного уменьшило MSE до 0,509 и увеличило explained variance score до 0,607. Для каждого варианта параметров приведены прогнозы трёх тестовых точек.

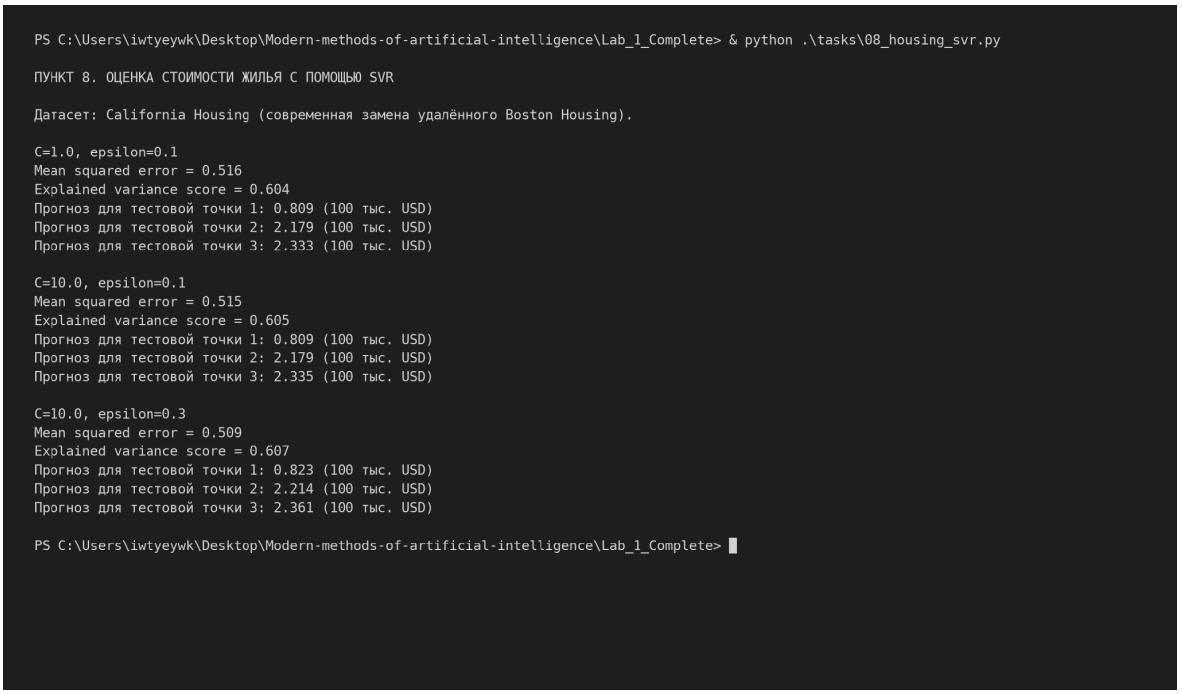


Рисунок 14 - Результаты оценки стоимости жилья регрессором SVR

9 Классификация изображений с применением Transfer Learning

Для задачи классификации изображений выбран встроенный набор sklearn Digits. Использованы три класса изображений: цифры 0, 1 и 2. После стратифицированного разделения выборки для обучения использовались 402 изображения, а для тестирования - 135. В качестве предобученной архитектуры выбрана MobileNetV2 с весами ImageNet. MobileNetV2 является компактной сверточной сетью, поэтому подходит для учебного эксперимента на центральном процессоре.

В стратегии Feature Extraction все веса базовой сети были заморожены, а обучался только новый выходной слой классификатора. Затем обучение продолжалось в стратегии Fine-tuning: был размерожен последний блок MobileNetV2, а темп обучения уменьшен с 0,001 до 0,0001. Такой подход позволяет осторожно адаптировать наиболее высокоуровневые признаки к новой задаче, не разрушая основную часть предобученной сети.

```
PS C:\Users\iwtyeywk\Desktop\Modern-methods-of-artificial-intelligence\Lab_1_Complete> & python .\tasks\09_transfer_learning.py

ПУНКТ 9. КЛАССИФИКАЦИЯ ИЗОБРАЖЕНИЙ С ПРИМЕНЕНИЕМ TRANSFER LEARNING

Датасет: sklearn Digits; классы: 0, 1, 2.
Обучение: 402 изображений; тест: 135 изображений.
Архитектура: MobileNetV2 с весами ImageNet.

Feature Extraction (заморожена базовая сеть, обучается fc):
Эпоха 1: loss=1.0372, train accuracy=47.76%
Эпоха 2: loss=0.8612, train accuracy=65.67%
Test Accuracy=79.26%
Test Precision=80.44%
Test Recall=79.26%

Fine-tuning (размерожен layer4 и fc; уменьшен learning rate):
Эпоха 3: loss=0.7921, train accuracy=69.65%
Эпоха 4: loss=0.7176, train accuracy=76.62%
Эпоха 5: loss=0.7022, train accuracy=78.11%
Эпоха 6: loss=0.6671, train accuracy=80.10%
Эпоха 7: loss=0.6339, train accuracy=81.34%
Test Accuracy=82.22%
Test Precision=84.70%
Test Recall=82.22%
Изменение Accuracy: +2.96%

PS C:\Users\iwtyeywk\Desktop\Modern-methods-of-artificial-intelligence\Lab_1_Complete>
```

Рисунок 15 - Консольный вывод эксперимента Transfer Learning

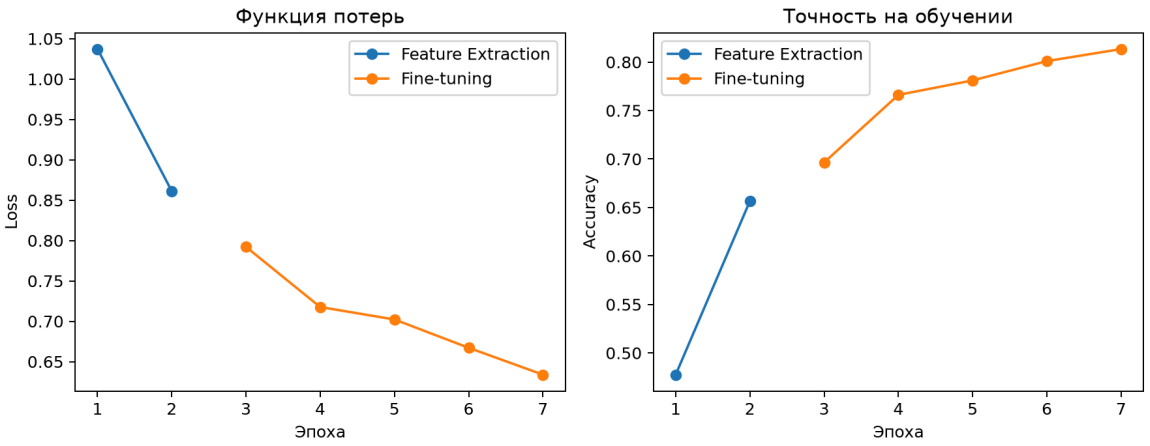


Рисунок 16 - Динамика функции потерь и точности обучения

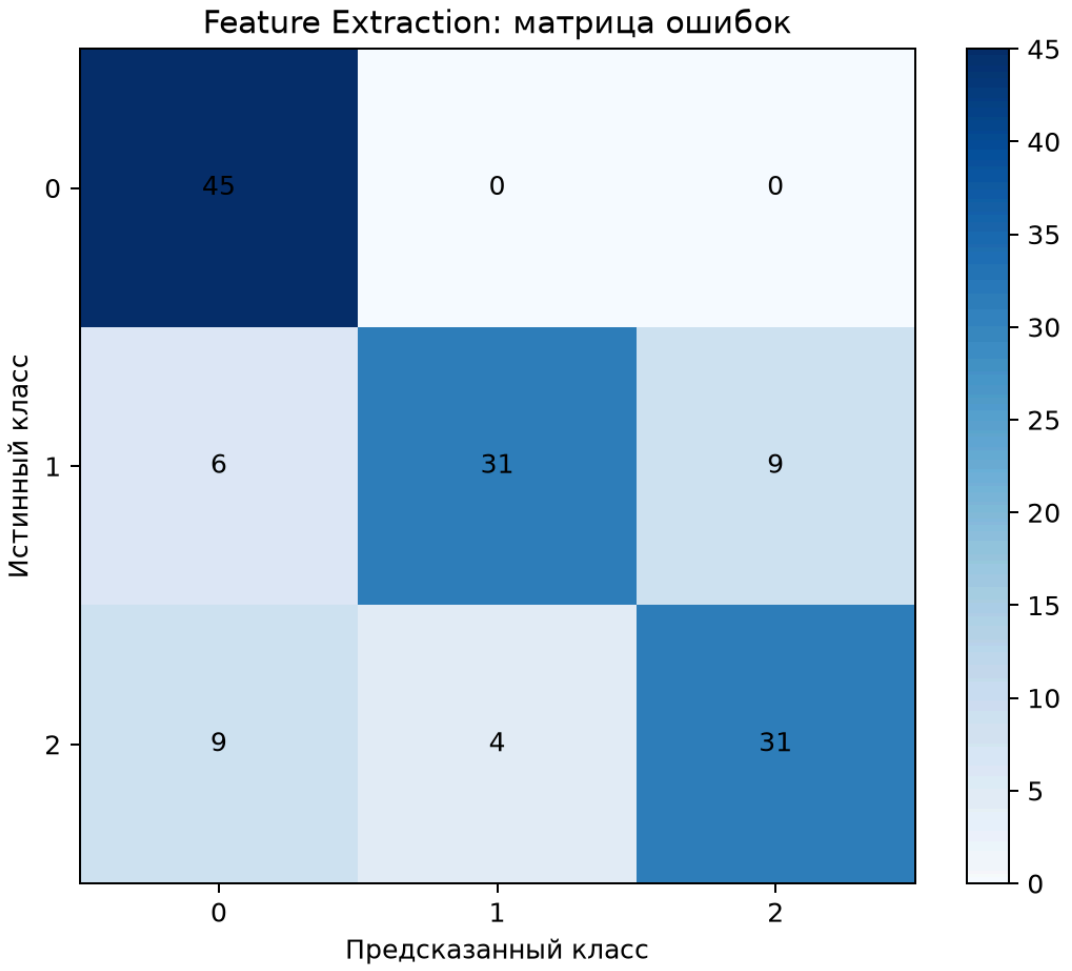


Рисунок 17 - Матрица ошибок Feature Extraction

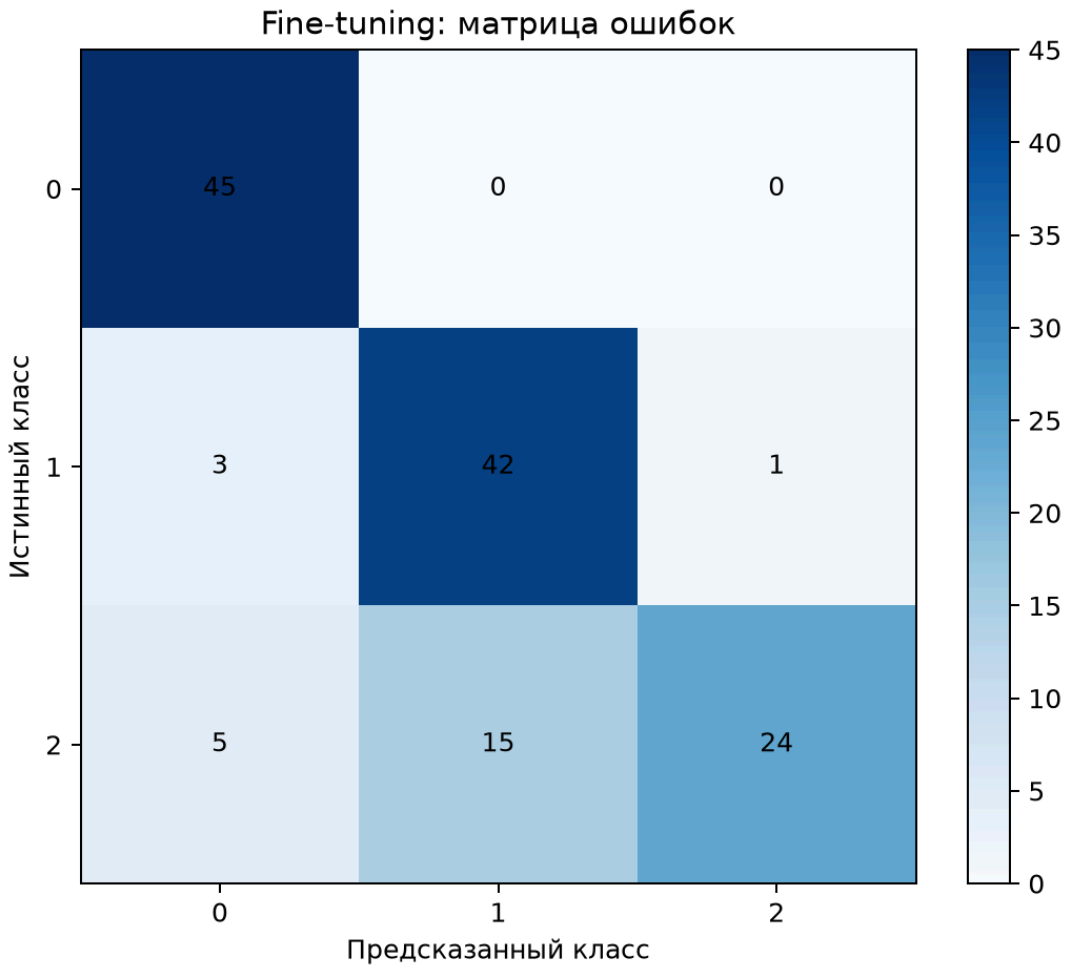


Рисунок 18 - Матрица ошибок Fine-tuning

При Feature Extraction на тестовой выборке получены Accuracy 79,26 процента, Precision 80,44 процента и Recall 79,26 процента. После Fine-tuning Accuracy увеличилась до 82,22 процента, Precision - до 84,70 процента, а Recall - до 82,22 процента. Прирост Accuracy составил 2,96 процентного пункта. Следовательно, в данном эксперименте дообучение последнего блока оказалось целесообразным: оно улучшило все основные метрики качества.

Заключение

В ходе лабораторной работы освоены базовые операции подготовки данных и практические методы обучения с учителем. Были исследованы логистическая регрессия, наивный байесовский классификатор, машина опорных векторов, линейная и полиномиальная регрессии, а также SVR. В задаче классификации изображений применение Transfer Learning с MobileNetV2 показало, что Fine-tuning последнего блока повышает Accuracy с 79,26 до 82,22 процента. Эксперименты подтвердили, что результат модели зависит от выбора признаков, способа подготовки данных, параметров регуляризации и объёма дообучаемой части сети. Все исходные программы, результаты запуска и графические артефакты организованы по отдельным файлам.